

Ön Eğitimli Vision Transformer Modellerinin ISIC2019 Veri Kümesi Üzerinde Eşit Fine-Tuning Koşulları Altında Karşılaştırmalı Analizi

Emirhan AYDIN

Bilgisayar Mühendisliği Doktora Programı, Tokat Gaziosmanpaşa Üniversitesi

emirhan.aydin@gop.edu.tr

Özet

Son yıllarda Vision Transformer (ViT) tabanlı mimariler, görüntü sınıflandırma problemlerinde Convolutional Neural Network (CNN) tabanlı yaklaşımlara güçlü alternatifler sunmuştur. Özellikle ön eğitimli transformer modellerinin transfer öğrenme ile ince ayar (fine-tuning) sürecine tabi tutulması, sınırlı veri kümelerinde yüksek performans elde edilmesini mümkün hâle getirmiştir. Bu çalışmada, dermatolojik görüntü sınıflandırma alanında yaygın olarak kullanılan ISIC2019 [1] veri kümesi üzerinde dokuz farklı Vision Transformer mimarisinin performansı karşılaştırılmıştır. Çalışma kapsamında BEiT [2], CaiT [3], ConViT [4], DeiT [5], PVTv2 [6], Swin Transformer [7], ViT [8], MaxViT [9] ve MobileViT [10] mimarileri aynı eğitim koşulları altında fine-tune edilmiştir. Tüm modeller için aynı ön işleme adımları, veri artırma stratejileri, görüntü boyutu, optimizör ve eğitim protokolü kullanılarak adil bir karşılaştırma ortamı oluşturulmuştur.

Modellerin performansları accuracy ve macro-F1 skorları ile değerlendirilmiş, ayrıca eğitim/doğrulama loss ve accuracy eğrileri incelenmiştir. Elde edilen sonuçlara göre en yüksek performansı Swin Transformer Small modeli elde etmiş olup %88.93 accuracy ve 0.8435 macro-F1 skoruna ulaşmıştır. Çalışma sonuçları, modern Vision Transformer mimarilerinin dermatolojik görüntü sınıflandırma problemlerinde yüksek performans sunduğunu ve kontrollü fine-tuning koşullarının model karşılaştırmalarında önemli rol oynadığını göstermektedir.

Anahtar Kelimeler: görüntü sınıflandırma, Vision Transformer, ISIC2019, transfer öğrenme, fine-tuning, deri lezyonu sınıflandırma

1. Giriş

Görüntü sınıflandırma, bilgisayarlı görü alanının en temel problemlerinden biri olup sağlık, savunma, güvenlik, otonom sistemler ve endüstriyel otomasyon gibi birçok farklı alanda kullanılmaktadır. Özellikle tıbbi görüntü analizi alanında geliştirilen otomatik sınıflandırma sistemleri, uzman desteğinin sınırlı olduğu durumlarda karar destek mekanizması olarak önemli avantajlar sağlamaktadır. Dermatolojik görüntü analizi de bu alanlardan biri olup, deri lezyonlarının erken teşhis edilmesi özellikle melanoma gibi ölümcül cilt kanserlerinin erken evrede tespit edilmesi açısından kritik öneme sahiptir.

Derin öğrenme tabanlı görüntü sınıflandırma çalışmalarında uzun yıllar boyunca CNN tabanlı mimariler baskın yaklaşım olmuştur. ResNet [11], DenseNet [12] ve EfficientNet [13] gibi CNN tabanlı modeller birçok görüntü sınıflandırma probleminde başarılı sonuçlar elde etmiştir. Ancak son yıllarda doğal dil işleme alanında geliştirilen Transformer mimarisinin görüntü işleme problemlerine uyarlanmasıyla birlikte ViT tabanlı modeller önemli bir araştırma alanı hâline gelmiştir. Vision Transformer mimarileri, görüntüyü parçalara ayırarak dikkat (self-attention) mekanizması üzerinden küresel ilişkileri öğrenebilmekte ve özellikle büyük veri kümelerinde güçlü performans gösterebilmektedir.

Literatürde Vision Transformer tabanlı birçok farklı mimari önerilmiş olsa da bu modellerin aynı veri kümesi ve aynı eğitim koşulları altında karşılaştırıldığı çalışmalar sınırlıdır. Farklı ön işleme yöntemleri, augmentation stratejileri, optimizör ayarları ve eğitim protokolleri, modeller arasında doğrudan karşılaştırma yapılmasını zorlaştırmaktadır. Bu nedenle kontrollü deney ortamlarında gerçekleştirilen karşılaştırmalar, modellerin gerçek performans farklarını analiz edebilmek açısından önem taşımaktadır.

Bu çalışmada ISIC2019 veri kümesi üzerinde farklı Vision Transformer mimarilerinin kontrollü fine-tuning koşulları altında performans analizi gerçekleştirilmiştir. Çalışma kapsamında tüm modeller aynı veri ayırımı, aynı augmentation stratejileri ve aynı eğitim protokolü kullanılarak eğitilmiş ve karşılaştırılmıştır.

Bu çalışmanın katkıları şu şekilde özetlenebilir:

- ISIC2019 veri kümesi üzerinde dokuz farklı Vision Transformer mimarisi aynı eğitim koşulları altında karşılaştırılmıştır.
- Tüm modeller için ortak ön işleme, veri artırma ve fine-tuning stratejisi kullanılarak adil bir deney ortamı oluşturulmuştur.
- Accuracy ve macro-F1 metrikleri birlikte değerlendirilmiş, ayrıca eğitim/doğrulama eğrileri ve hata analizleri incelenmiştir.

2. İlgili Çalışmalar

Deri lezyonu sınıflandırma problemi, son yıllarda derin öğrenme tabanlı yöntemlerin hızlı gelişimi ile birlikte önemli bir araştırma alanı hâline gelmiştir. Literatürde erken dönem çalışmaların büyük bir kısmı CNN tabanlı yaklaşımlara dayanmaktadır. Bu kapsamda, Inception, ResNet ve EfficientNet gibi mimarilerin transfer öğrenme ile kullanıldığı çalışmalar, ISIC veri kümeleri üzerinde yüksek başarımlar elde etmiştir. Örneğin Gouda ve arkadaşları, ISIC 2018 veri seti üzerinde ESRGAN tabanlı görüntü iyileştirme ile birlikte ResNet50, InceptionV3 ve Inception-ResNet modellerini karşılaştırmış ve en yüksek performansı %85,8 doğruluk ile InceptionV3 modelinde elde etmiştir [14]. Benzer şekilde Iqbal ve arkadaşları tarafından önerilen CSLNet modeli, çok sınıflı deri lezyonu sınıflandırmasında ISIC 2017, 2018 ve 2019 veri setlerinde yüksek doğruluk değerleri elde ederek özelleştirilmiş CNN mimarilerinin etkisini göstermiştir [15].

CNN tabanlı yaklaşımlara ek olarak, sınıf dengesizliği problemini ele alan çalışmalar da literatürde önemli bir yer tutmaktadır. Tahir ve arkadaşları, SMOTE-Tomek örnekleme yöntemi ile veri dengesizliğini gidererek DSCC_Net adlı CNN tabanlı bir model önermiş ve ISIC 2020, HAM10000 ve DermIS veri setlerinde yüksek AUC ve doğruluk değerlerine ulaşmıştır [16]. Ayrıca Yao ve arkadaşları, küçük ve dengesiz veri setleri için RegNet tabanlı tek model yaklaşımını önermiş, Multi-Weighted New Loss (MWNL) fonksiyonu ve kümülatif öğrenme stratejisi ile ensemble modellere kıyasla rekabetçi sonuçlar elde etmiştir [17]. Bu çalışmalar, veri dengesizliğinin dermatolojik görüntü sınıflandırmada kritik bir problem olduğunu göstermektedir.

Son yıllarda ViT tabanlı ve hibrit mimarilerin ortaya çıkmasıyla birlikte, görüntü sınıflandırma alanında yeni bir paradigma değişimi yaşanmıştır. Ayas, Swin Transformer tabanlı bir model önererek CNN ve Transformer mimarilerinin avantajlarını birleştirmiş ve ISIC 2019 veri seti üzerinde %82,3 balanced accuracy elde etmiştir [18]. Bu çalışmada ayrıca weighted cross entropy loss kullanılarak sınıf dengesizliği problemi ele alınmıştır. Benzer şekilde, Pacal ve arkadaşları MetaFormer tabanlı bir yapı üzerinde focal self-attention mekanizması geliştirerek hem ISIC 2019 hem HAM10000 veri setlerinde yüksek doğruluk değerlerine ulaşmış ve kritik bölgelere odaklanma kabiliyeti ile model performansını artırmıştır [19].

Hibrit CNN–Transformer yaklaşımları da literatürde dikkat çekmektedir. Nigar ve arkadaşları, ResNet-18 ve LIME tabanlı bir açıklanabilir yapay zekâ yaklaşımı önererek model kararlarının görsel olarak yorumlanmasını sağlamış ve %94,47 doğruluk elde etmiştir [20]. Özdemir ve Pacal (2025), ConvNeXtV2 blokları ile ayrılabilir self-attention mekanizmasını birleştiren kompakt bir hibrit model önermiş ve ISIC 2019 veri setinde %93,48 doğruluk elde ederek birçok modern CNN ve Vision Transformer modelini geride bırakmıştır [21]. Bu tür hibrit yapılar, yerel özellik çıkarımı ile küresel bağıntı öğrenimini aynı çatı altında birleştirmesi açısından önemli avantajlar sunmaktadır.

Buna ek olarak, model performansını artırmak amacıyla çoklu model toplulukları (ensemble learning) ve ek veri kaynaklarının kullanıldığı çalışmalar da mevcuttur. Gessert ve arkadaşları, EfficientNet, SENet ve ResNeXt tabanlı modellerden oluşan bir ensemble yaklaşımı önermiş ve hasta meta verilerini (yaş, cinsiyet vb.) modele dahil ederek sınıflandırma başarımını artırmıştır [22]. Ayrıca Kassem ve arkadaşları, GoogleNet mimarisini transfer öğrenme ile geliştirerek ISIC 2019 veri setinde %94,92 doğruluk elde etmiş ve “bilinmeyen sınıf” tespiti için ek bir SVM tabanlı yaklaşım önermiştir [23].

Genel olarak literatür incelendiğinde üç temel eğilim dikkat çekmektedir. İlk olarak, CNN tabanlı klasik yaklaşımlar hâlâ güçlü bir temel oluşturmakla birlikte, Transformer tabanlı modellerin özellikle küresel bağlam öğrenme kapasitesi nedeniyle giderek daha yaygın hale geldiği görülmektedir. İkinci olarak, sınıf dengesizliği problemi veri artırma, yeniden örnekleme ve özel kayıp fonksiyonları ile çözülmeye çalışılmaktadır. Üçüncü olarak ise hibrit CNN–Transformer mimarilerinin hem yerel hem de küresel özellikleri birlikte öğrenebilmesi nedeniyle yüksek performans sunduğu gözlemlenmektedir. Bununla birlikte, literatürde farklı çalışmaların farklı eğitim protokolleri ve veri ön işleme yöntemleri kullanması, modellerin doğrudan karşılaştırılmasını zorlaştırmaktadır. Bu durum, kontrollü fine-tuning koşulları altında Vision Transformer tabanlı modellerin karşılaştırıldığı çalışmaların önemini artırmaktadır.

Tablo 1. Literatürdeki benzer çalışmaların kısa özeti

Çalışma	Veri Kümesi / Problem	Yöntem	Metrik / Sonuç	Kısa Not
Ayas (2023)	ISIC 2019 – çok sınıflı deri lezyonu sınıflandırma	Swin Transformer + weighted cross entropy	%82.3 balanced accuracy	Transformer + CNN hibrit yaklaşım, ön işleme ihtiyacı olmadan çalışma
Gessert ve ark. (2020)	ISIC 2019 – deri lezyonu sınıflandırma	EfficientNet, SENet, ResNeXt WSL ensemble + metadata fusion	Performans artırımı (metrik verilmemiş)	Hasta yaşı/cinsiyeti gibi meta veriler kullanılmış
Gouda ve ark. (2022)	ISIC 2018 – benign/malign sınıflandırma	ESRGAN + ResNet50 / InceptionV3 / Inception-ResNet	%85.8 (InceptionV3)	Görüntü iyileştirme ile performans artırımı
Iqbal ve ark. (2021)	ISIC 2017/2018/2019 – çok sınıflı sınıflandırma	CSLNet (özel CNN)	%94 accuracy / %93 recall (ISIC 2017)	Hafif ve verimli CNN mimarisi
Kassem ve ark. (2020)	ISIC 2019 – 8 sınıf sınıflandırma	Modified GoogLeNet + transfer learning + SVM	%94.92 accuracy	“Unknown class” tespiti ek yaklaşım
Nigar ve ark. (2022)	ISIC 2019 – deri lezyonu sınıflandırma	ResNet-18 + LIME (XAI)	%94.47 accuracy	Açıklanabilir AI ile görsel yorumlanabilirlik
Özdemir & Pacal (2025)	ISIC 2019 – sınıflandırma	ConvNeXtV2 + separable self-attention (hibrit)	%93.48 accuracy	Kompakt hibrit model, CNN + attention birleşimi
Pacal ve ark. (2025)	ISIC 2019 / HAM10000	MetaFormer + focal self-attention	%92.54 / %95.01 accuracy	Kritik bölgelere odaklanan attention mekanizması
Tahir ve ark. (2023)	ISIC 2020 / HAM10000 / DermIS	CNN (DSCC_Net) + SMOTE-Tomek	%94.17 accuracy / %99.43 AUC	Veri dengesizliği SMOTE ile çözülmüş
Yao ve ark. (2022)	Küçük ve dengesiz veri setleri	RegNet + MWNL loss + cumulative learning	Rekabetçi sonuçlar	Ensemble yerine tek model, düşük maliyet


3. Materyal ve Yöntem

3.1. Veri Kümesi

Bu çalışmada, dermatolojik görüntü sınıflandırma alanında yaygın olarak kullanılan ISIC2019 veri kümesi kullanılmıştır. Veri kümesi, farklı deri lezyonu türlerine ait toplam 25 331 dermoskopik görüntü içermekte olup sekiz farklı sınıftan oluşmaktadır. ISIC2019 veri kümesi, sınıflar arasında belirgin örnek sayısı farklılıkları içermesi nedeniyle sınıf dengesizliği problemini barındırmaktadır. Ayrıca bazı lezyon türlerinin görsel olarak birbirine oldukça benzer olması, sınıflandırma görevini daha da zorlaştırmaktadır.

Çalışma kapsamında veri kümesi eğitim, doğrulama ve test alt kümelerine ayrılmıştır. Veri ayrımı %80 eğitim, %10 doğrulama ve %10 test olacak şekilde gerçekleştirilmiştir. Tüm modeller aynı veri ayrımı kullanılarak eğitilmiş ve değerlendirilmiştir. Böylece farklı ViT mimarilerinin performanslarının adil koşullar altında karşılaştırılması amaçlanmıştır.

Şekil 1’de veri kümesinde yer alan farklı sınıflara ait örnek görüntüler gösterilmektedir. Görüntüler incelendiğinde bazı sınıfların benzer renk, doku ve şekil özelliklerine sahip olduğu görülmekte olup bu durum sınıflandırma probleminin zorluk seviyesini artırmaktadır.



Şekil 1. ISIC2019 veri kümesinde bulunan farklı deri lezyonu sınıflarına ait örnek görüntüler.

3.2. Ön İşleme ve Veri Hazırlama

Tüm görüntüler modele girdi olarak verilmeden önce 224×224 piksel boyutuna dönüştürülmüştür. Eğitim aşamasında modelin genelleme yeteneğini artırmak amacıyla veri artırma (data augmentation) teknikleri uygulanmıştır. Bu kapsamda rastgele yeniden boyutlandırma ve kırpma (Random Resized Crop), yatay çevirme (Random Horizontal Flip) ve renk değişimi (Color Jitter) işlemleri kullanılmıştır. Doğrulama ve test aşamalarında ise görüntüler önce yeniden boyutlandırılmış, ardından merkezden kırılarak modele verilmiştir.

Görüntüler, ön eğitilmiş modeller ile uyumlu olacak şekilde ImageNet veri kümesinin ortalama ve standart sapma değerleri kullanılarak normalize edilmiştir. Böylece transfer öğrenme sürecinde kullanılan ön eğitilmiş ağırlıkların daha etkili biçimde kullanılabilmesi sağlanmıştır.

3.3. Kullanılan Yaklaşım / Modeller

Bu çalışmada farklı Vision Transformer mimarilerinin kontrollü fine-tuning koşulları altında karşılaştırılması amaçlanmıştır. Modeller, timm kütüphanesi kullanılarak ön eğitilmiş (pretrained) ağırlıklarla yüklenmiş ve son sınıflandırma katmanları ISIC2019 veri kümesindeki sınıf sayısına uygun şekilde yeniden yapılandırılmıştır.

Çalışma kapsamında BEiT, CaiT, ConViT, DeiT, PVTv2, Swin Transformer, ViT, MobileViT ve MaxViT mimarileri değerlendirilmiştir. Tüm modeller için aynı veri artırma stratejileri, aynı optimizasyon yöntemi ve aynı eğitim protokolü kullanılarak adil bir karşılaştırma ortamı oluşturulmuştur.

Transfer öğrenme yaklaşımı tercih edilmiştir. Bu sayede ImageNet üzerinde önceden öğrenilmiş özellik temsilleri kullanılarak sınırlı sayıda tıbbi görüntü ile yüksek performans elde edilmesi hedeflenmiştir.

3.4. Deneysel Kurulum

Deneysel Python programlama dili kullanılarak gerçekleştirilmiş olup derin öğrenme altyapısı olarak PyTorch kütüphanesinden yararlanılmıştır. Vision Transformer modellerinin oluşturulması ve ön eğitilmiş ağırlıklarının yüklenmesi için timm kütüphanesi kullanılmıştır. Eğitimler NVIDIA GeForce RTX 3060 grafik işlemcisi üzerinde gerçekleştirilmiştir.

Çalışma kapsamında BEiT, CaiT, ConViT, DeiT, PVTv2, Swin Transformer, ViT, MobileViT ve MaxViT mimarileri değerlendirilmiştir. Tüm modeller aynı veri artırma, aynı ön işleme adımları, aynı veri artırma stratejileri ve aynı eğitim parametreleri kullanılarak eğitilmiştir. Böylece modeller arasında adil bir karşılaştırma ortamı oluşturulması amaçlanmıştır.

Tüm modeller için giriş görüntü boyutu 224×224 piksel olarak belirlenmiştir. Eğitim sürecinde batch size değeri 32, maksimum epoch sayısı ise 50 olarak seçilmiştir. Transfer öğrenme yaklaşımı kullanılmış ve tüm modeller ImageNet üzerinde ön eğitilmiş ağırlıklarla başlatılmıştır. Model parametrelerinin güncellenmesinde AdamW optimizasyon algoritması tercih edilmiş, başlangıç öğrenme oranı 10^{-4} ve weight decay değeri 10^{-4} olarak ayarlanmıştır.

Kayıp fonksiyonu olarak çok sınıflı sınıflandırma problemlerinde yaygın olarak kullanılan Cross Entropy Loss [24] kullanılmıştır. Eğitim sürecinde doğrulama kaybı takip edilmiş ve öğrenme oranının dinamik olarak ayarlanabilmesi amacıyla ReduceLROnPlateau [25] öğrenme oranı zamanlayıcısından yararlanılmıştır. Doğrulama kaybında dört epoch boyunca iyileşme gözlenmediğinde öğrenme oranı yarıya düşürülmüştür.

Ayrıca aşırı öğrenmeyi önlemek amacıyla erken durdurma (Early Stopping) [26] mekanizması uygulanmıştır. Doğrulama kaybında on epoch boyunca iyileşme görülmemesi durumunda eğitim sonlandırılmıştır. Her epoch sonunda doğruluk, precision, recall ve macro-F1 [27] metrikleri hesaplanmış, en düşük doğrulama kaybına sahip model ağırlıkları kaydedilerek nihai değerlendirmelerde kullanılmıştır.

3.5. Değerlendirme Metrikleri

Modellerin performansını değerlendirmek amacıyla doğruluk (Accuracy), kesinlik (Precision), duyarlılık (Recall) ve F1-Skoru metrikleri kullanılmıştır. Precision, Recall ve F1-Skoru hesaplamalarında tüm sınıfların eşit ağırlıkla değerlendirilmesini sağlayan macro ortalama yöntemi tercih edilmiştir.

Accuracy metriği, doğru sınıflandırılan örneklerin toplam örnek sayısına oranını göstermektedir. Precision, model tarafından belirli bir sınıfa atanan örneklerin ne kadarının gerçekten o sınıfa ait olduğunu ifade ederken; Recall, ilgili sınıfa ait örneklerin ne kadarının doğru şekilde tespit edildiğini göstermektedir. F1-Skoru ise Precision ve Recall metriklerinin harmonik ortalamasıdır.

Bunun yanında sınıflar arasındaki hata dağılımını incelemek amacıyla karışıklık matrisi (Confusion Matrix) oluşturulmuş ve modellerin hangi sınıfları birbirleriyle karıştırdığı analiz edilmiştir.


4. Bulgular

Bu bölümde ISIC 2019 veri kümesi üzerinde fine-tuning uygulanarak eğitilen dokuz farklı Vision Transformer tabanlı modelin sonuçları sunulmaktadır. Tüm modeller aynı veri bölme oranı (%80 eğitim, %10 doğrulama, %10 test), aynı ön işleme adımları ve aynı eğitim parametreleri kullanılarak değerlendirilmiştir. Böylece elde edilen sonuçların doğrudan karşılaştırılabilir olması sağlanmıştır.

Tablo 2. Deneysel sonuçların karşılaştırılması.


Model	Ön eğitilmiş?	Augmentation	Accuracy	Precision	Recall	F1-Score	Eğitim Süresi (dk - epoch)
BEiT-Base	Evet	Var	0.8506	0.8401	0.7535	0.7908	226.2 dk - 34 epoch
CaiT-XXS36	Evet	Var	0.8465	0.8075	0.7611	0.7779	125.3 dk - 28 epoch
ConViT-Tiny	Evet	Var	0.8244	0.7677	0.7193	0.7401	60.0 dk - 32 epoch
DeiT-Small	Evet	Var	0.8650	0.8596	0.7791	0.8110	73.5 dk - 29 epoch
MaxViT-Tiny	Evet	Var	0.8784	0.8368	0.8183	0.8256	384.7 dk - 25 epoch
MobileViT-XS	Evet	Var	0.8461	0.7744	0.7486	0.7603	143.0 dk - 50 epoch
PVT-v2-B0	Evet	Var	0.8540	0.8071	0.7686	0.7857	55.7 dk - 32 epoch
*Swin-Small	Evet	Var	0.8893	0.8681	0.8241	0.8435	141.5 dk - 28 epoch
ViT-Small	Evet	Var	0.8654	0.8382	0.7804	0.8052	83.1 dk - 31 epoch

Sonuçlar incelendiğinde en yüksek doğruluk (%88.93) ve Macro-F1 (%84.35) değerlerinin Swin-Small modeli tarafından elde edildiği görülmektedir. Swin-Small modelini %87.84 doğruluk ve %82.56 Macro-F1 ile MaxViT-Tiny modeli takip etmiştir. MobileViT-XS ve ConViT-Tiny modelleri ise diğer modellere kıyasla daha düşük performans göstermiştir.



Şekil 2. Tüm modeller için test kümesi üzerinde Macro-F1 ve Accuracy skorları.


Şekil 2'de test kümesi üzerinde elde edilen doğruluk ve Macro-F1 skorları gösterilmektedir. Accuracy açısından en başarılı model %88.93 ile Swin-Small olurken, Macro-F1 metriğinde de %84.35 ile ilk sırada yer almıştır. Veri kümesindeki sınıf dengesizliği göz önüne alındığında Macro-F1 metriği daha anlamlı bir değerlendirme sunmaktadır. Bu açıdan Swin-Small modelinin yalnızca baskın sınıflarda değil, az örnekli sınıflarda da daha dengeli bir performans sergilediği görülmektedir.



Şekil 3. Tüm modeller için eğitim/doğrulama loss ve accuracy eğrileri.


Şekil 3'te dokuz farklı Vision Transformer modeline ait eğitim ve doğrulama accuracy ile loss eğrileri birlikte sunulmaktadır. Genel olarak tüm modellerde eğitim accuracy değerlerinin doğrulama accuracy değerlerinden daha yüksek olduğu görülmektedir. Modeller arasında değişimle birlikte eğitim ve doğrulama doğruluğu arasında yaklaşık %5–15 seviyesinde bir fark olduğu gözlemlenmiştir. Bu durum modellerin eğitim verisini doğrulama verisine kıyasla daha iyi öğrendiğini göstermektedir.

Bununla birlikte birçok modelde doğrulama accuracy değerleri eğitimin ilerleyen epochlarında artmaya devam etmesine rağmen doğrulama loss değerlerinde belirgin bir iyileşme gözlenmemiştir. Bu nedenle eğitim sürecinde erken durdurma mekanizması doğrulama loss metriği üzerinden uygulanmıştır. Accuracy'deki sınırlı artışlara rağmen loss değerlerinin uzun süre iyileşmemesi, modellerin genelleme performansında anlamlı bir kazanım elde edemediğini göstermektedir.




Şekil 4. Modellerin eğitim ve doğrulama accuracy karşılaştırması.

Şekil 4 incelendiğinde tüm modellerin eğitim doğruluklarının doğrulama doğruluklarından daha yüksek olduğu görülmektedir. Swin-Small ve MaxViT-Tiny modelleri hem eğitim hem de doğrulama aşamasında en yüksek doğruluk değerlerine ulaşırken, MobileViT-XS ve ConViT-Tiny modelleri daha düşük doğruluk seviyelerinde kalmıştır. MobileViT-XS modelinde eğitim ve doğrulama doğrulukları arasındaki farkın diğer modellere kıyasla daha düşük olması dikkat çekmektedir. Bu durum modelin daha düşük temsil kapasitesi nedeniyle eğitim verisine aşırı uyum göstermediğini, ancak aynı zamanda ulaşabileceği maksimum performansın da sınırlı kaldığını göstermektedir.



Şekil 5. Modellerin eğitim ve doğrulama loss karşılaştırması.

Şekil 5'de eğitim ve doğrulama kayıplarının model bazında değişimi gösterilmektedir. Genel olarak tüm modellerde eğitim kaybı düzenli olarak azalırken doğrulama kaybı belirli bir seviyeden sonra plato eğilimi göstermiştir. Özellikle yüksek kapasiteli modellerde eğitim kaybı düşmeye devam ederken doğrulama kaybındaki iyileşmenin sınırlı kalması, ek eğitim süresinin genelleme performansına önemli katkı sağlamadığını göstermektedir. Bu gözlem, eğitim sürecinde kullanılan erken durdurma stratejisinin uygun olduğunu desteklemektedir. En düşük doğrulama kaybı Swin-Small modelinde elde edilmiş olup bu durum test kümesindeki en yüksek accuracy ve Macro-F1 sonuçlarıyla da uyumludur.



Şekil 6. Swin-Small modelinin karmaşıklık matrisi.

En yüksek performansı elde eden Swin-Small modelinin karmaşıklık matrisi incelendiğinde modelin özellikle NV (Melanocytic Nevus), MEL (Melanoma), BCC (Basal Cell Carcinoma) ve VASC (Vascular Lesion) sınıflarında yüksek başarı gösterdiği görülmektedir. Bununla birlikte sınıflar arasında belirli düzeyde karışmalar da mevcuttur. En belirgin hata, MEL ve NV sınıfları arasında gözlenmiştir. Test kümesinde 116 adet MEL örneği NV olarak sınıflandırılırken, 105 adet NV örneği de MEL olarak tahmin edilmiştir. Bu durum, iki sınıfın dermoskopik görüntülerde benzer renk, doku ve yapısal özellikler göstermesi nedeniyle literatürde de sıkça raporlanan bir problemdir.

Karmaşıklık matrisi ayrıca BKL sınıfının MEL ve NV sınıfları ile belirli ölçüde karıştırıldığını göstermektedir. BKL örneklerinin 39 adedi MEL, 34 adedi ise NV olarak sınıflandırılmıştır. Benzer şekilde AK sınıfında da BCC ve BKL sınıflarına yönelik hatalar gözlenmiştir. Buna karşılık DF ve VASC sınıflarında sınıflandırma başarısının oldukça yüksek olduğu görülmektedir. DF sınıfında 49 örneğin 38'i, VASC sınıfında ise 51 örneğin 45'i doğru şekilde sınıflandırılmıştır. Genel olarak sonuçlar, modelin baskın sınıflarda yüksek başarı sağladığını ancak görsel olarak benzer lezyon tipleri arasında ayrım yapmanın hâlen zorlayıcı olduğunu göstermektedir.

5. Tartışma

Bu çalışmada ISIC 2019 veri kümesi üzerinde farklı Vision Transformer tabanlı mimarilerin deri lezyonu sınıflandırma performansları karşılaştırılmıştır. Tüm modeller aynı veri bölünmesi (%80 eğitim, %10 doğrulama, %10 test), aynı görüntü boyutu (224×224), aynı veri artırma stratejileri ve benzer fine-tuning koşulları altında eğitilmiştir. Böylece performans farklılıklarının büyük ölçüde model mimarisinden kaynaklanması hedeflenmiştir.

Elde edilen sonuçlar, Swin-Small modelinin %88,93 doğruluk, %86,81 Macro-Precision, %82,41 Macro-Recall ve %84,35 Macro-F1 skoru ile tüm modeller arasında en başarılı performansı sergilediğini göstermektedir. Swin Transformer mimarisinin kaydırmalı pencere (shifted window) tabanlı hiyerarşik dikkat mekanizması sayesinde hem yerel hem de küresel özellikleri etkili şekilde öğrenebildiği düşünülmektedir.

Klasik Vision Transformer tabanlı modellerden ViT-Small (%86,54 doğruluk, %80,52 Macro-F1) ve DeiT-Small (%86,50 doğruluk, %81,10 Macro-F1) modelleri başarılı sonuçlar üretmiştir. Ayrıca MaxViT-Tiny (%87,84 doğruluk, %82,56 Macro-F1) modeli de Swin-Small'ın ardından en yüksek performans gösteren modeller arasında yer almıştır. Buna karşılık MobileViT-XS modeli %84,61 doğruluk ve %76,03 Macro-F1 skoru ile düşük performans gösteren modeller arasında yer almıştır. MobileViT'nin düşük parametre sayısı ve mobil cihazlara yönelik optimize edilmiş yapısı nedeniyle temsil kapasitesinin diğer modellere kıyasla daha sınırlı kaldığı değerlendirilmektedir.

Karışıklık matrisleri incelendiğinde özellikle MEL (Melanoma) ve NV (Melanocytic Nevus) sınıfları arasında önemli miktarda yanlış sınıflandırma gerçekleştiği görülmüştür. Bu durum literatürde de sıkça raporlanan bir problemdir ve iki sınıfın benzer renk, doku ve şekil özellikleri taşımasından kaynaklanmaktadır. Benzer şekilde AK, BKL ve SCC sınıflarında da belirli düzeyde karışmalar gözlenmiştir. Buna karşın DF ve VASC gibi daha belirgin görsel özelliklere sahip sınıflarda sınıflandırma başarısının oldukça yüksek olduğu görülmektedir.

Sonuçlar literatürde bildirilen çalışmalarla genel olarak uyumludur. Ancak doğrudan karşılaştırma yapılırken kullanılan veri bölünmesi, eğitim süresi, görüntü çözünürlüğü, veri artırma yöntemleri ve değerlendirme metriklerindeki farklılıkların dikkate alınması gerekmektedir. Bu nedenle elde edilen sonuçlar, literatürdeki değerlerle birebir kıyaslanmak yerine benzer koşullar altında değerlendirilmelidir.

Tablo 3. Literatürle kısa karşılaştırma.

Çalışma	Veri Kümesi	Yöntem	Metrik	Raporlanan Sonuç	Yorum
Ayas (2023)	ISIC 2019	Swin Transformer	Balanced Accuracy	%82,3	Aynı veri kümesi kullanılmıştır ancak farklı metrik ve eğitim protokolü uygulanmıştır.
Özdemir ve Pacal (2025)	ISIC 2019	Hibrit CNN-Transformer	Accuracy	%93,48	Daha karmaşık hibrit yapı kullanılmıştır. Eğitim ayrıntıları farklı olduğundan doğrudan karşılaştırma sınırlıdır.
Kassem vd.	ISIC 2019	GoogleNet + Transfer Learning	Accuracy	%94,92	Farklı CNN tabanlı yaklaşım ve farklı deneysel kurulum kullanılmıştır.
Bu çalışma	ISIC 2019	Swin-Small	Accuracy / Macro-F1	%88,93 / %84,35	Tüm Transformer modelleri aynı koşullarda karşılaştırılmıştır.

5.1. Sınırlılıklar

Bu çalışmanın bazı sınırlılıkları bulunmaktadır. İlk olarak tüm deneyler tek bir rastgele başlangıç değeri (seed) ile gerçekleştirilmiştir. Farklı seed değerleri kullanılarak yapılan çoklu deneyler daha güvenilir performans değerlendirmeleri sağlayabilir. İkinci olarak eğitimler NVIDIA RTX 3060 ekran kartının hesaplama kapasitesi nedeniyle en fazla 50 epoch ile sınırlandırılmıştır. Daha uzun eğitim süreleri bazı modellerin performansını artırabilir.

Bir diğer sınırlılık ISIC 2019 veri kümesindeki sınıf dengesizliğidir. Özellikle NV sınıfı diğer sınıflara göre çok daha fazla örnek içerdiğinden model eğitiminde belirli sınıflara karşı önyargı oluşabilmektedir. Bu çalışmada veri artırma yöntemleri uygulanmış olsa da sınıf ağırlıklı kayıp fonksiyonları veya yeniden örnekleme teknikleri kullanılmamıştır.

Ayrıca yalnızca önceden eğitilmiş modellerin fine-tuning performansı incelenmiştir. Farklı görüntü çözünürlükleri, farklı veri artırma stratejileri veya self-supervised ön eğitim yaklaşımlarının etkileri araştırılmamıştır. Son olarak literatürdeki çalışmalarla yapılan karşılaştırmaların veri bölünmesi ve eğitim protokollerindeki farklılıklar nedeniyle sınırlı olduğu unutulmamalıdır.

6. Sonuç ve Gelecek Çalışmalar

Bu çalışmada ISIC 2019 veri kümesi üzerinde dokuz farklı Vision Transformer tabanlı mimarinin deri lezyonu sınıflandırma performansları karşılaştırılmıştır. Tüm modeller aynı veri bölünmesi, veri artırma stratejileri ve

eğitim parametreleri altında değerlendirilmiştir. Elde edilen sonuçlar Swin-Small modelinin %88,93 doğruluk ve %84,35 Macro-F1 skoru ile en başarılı model olduğunu göstermiştir. MaxViT-Tiny, ViT-Small ve DeiT-Small modelleri de yüksek performans sergilemiş, MobileViT-XS ise en düşük Macro-F1 başarımına ulaşmıştır.

Sonuçlar, yerel ve küresel özellik öğrenimini birlikte gerçekleştirebilen hibrit Transformer mimarilerinin deri lezyonu sınıflandırma problemlerinde avantaj sağlayabildiğini göstermektedir. Bununla birlikte sınıf dengesizliği ve görsel olarak benzer sınıflar arasındaki ayrımın hâlen önemli bir zorluk olduğu görülmüştür.

Gelecek çalışmalarda sınıf dengesizliğini azaltmak amacıyla focal loss, class-balanced loss veya yeniden örnekleme yöntemleri kullanılabilir. Ayrıca daha yüksek çözünürlüklü görüntüler, daha güçlü veri artırma teknikleri ve farklı ön eğitim stratejilerinin etkisi araştırılabilir. Grad-CAM ve attention map tabanlı açıklanabilir yapay zekâ yöntemleri kullanılarak modellerin karar mekanizmalarının incelenmesi de klinik güvenilirlik açısından önemli katkılar sağlayabilir. Bunun yanında çoklu seed deneyleri ve harici veri kümeleri üzerinde gerçekleştirilecek doğrulama çalışmaları sonuçların genellenebilirliğini artıracaktır.

Kaynakça

- [1] P. Tschandl, C. Rosendahl, and H. Kittler, ‘The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions’, *Sci Data*, vol. 5, no. 1, p. 180161, Aug. 2018, doi: 10.1038/sdata.2018.161.
- [2] H. Bao, L. Dong, S. Piao, and F. Wei, ‘BEiT: BERT Pre-Training of Image Transformers’, Sep. 03, 2022, *arXiv*: arXiv:2106.08254. doi: 10.48550/arXiv.2106.08254.
- [3] H. Touvron, M. Cord, A. Sablayrolles, G. Synnaeve, and H. Jégou, ‘Going Deeper With Image Transformers’, presented at the Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021, pp. 32–42. Accessed: Jun. 02, 2026. [Online]. Available: https://openaccess.thecvf.com/content/ICCV2021/html/Touvron_Going_Deepier_With_Image_Transformers_ICCV_2021_paper.html
- [4] S. D’Ascoli, H. Touvron, M. L. Leavitt, A. S. Morcos, G. Biroli, and L. Sagun, ‘ConViT: Improving Vision Transformers with Soft Convolutional Inductive Biases’, in *Proceedings of the 38th International Conference on Machine Learning*, PMLR, Jul. 2021, pp. 2286–2296. Accessed: Jun. 02, 2026. [Online]. Available: <https://proceedings.mlr.press/v139/d-ascoli21a.html>
- [5] H. Touvron, M. Cord, M. Douze, F. Massa, A. Sablayrolles, and H. Jégou, ‘Training data-efficient image transformers & distillation through attention’, in *Proceedings of the 38th International Conference on Machine Learning*, PMLR, Jul. 2021, pp. 10347–10357. Accessed: Jun. 05, 2026. [Online]. Available: <https://proceedings.mlr.press/v139/touvron21a.html>
- [6] W. Wang *et al.*, ‘PVT v2: Improved baselines with pyramid vision transformer’, *Computational Visual Media*, vol. 8, no. 3, pp. 415–424, Sep. 2022, doi: 10.1007/s41095-022-0274-8.
- [7] Z. Liu *et al.*, ‘Swin Transformer: Hierarchical Vision Transformer Using Shifted Windows’, presented at the Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021, pp. 10012–10022. Accessed: Jun. 02, 2026. [Online]. Available: https://openaccess.thecvf.com/content/ICCV2021/html/Liu_Swin_Transformer_Hierarchical_Vision_Transformer_Using_Shifted_Windows_ICCV_2021_paper
- [8] K. Han *et al.*, ‘A Survey on Vision Transformer’, *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 45, no. 1, pp. 87–110, Jan. 2023, doi: 10.1109/TPAMI.2022.3152247.
- [9] Z. Tu *et al.*, ‘MaxViT: Multi-axis Vision Transformer’, in *Computer Vision – ECCV 2022*, S. Avidan, G. Brostow, M. Cissé, G. M. Farinella, and T. Hassner, Eds, Cham: Springer Nature Switzerland, 2022, pp. 459–479. doi: 10.1007/978-3-031-20053-3_27.
- [10] S. Mehta and M. Rastegari, ‘MobileViT: Light-weight, General-purpose, and Mobile-friendly Vision Transformer’, Mar. 04, 2022, *arXiv*: arXiv:2110.02178. doi: 10.48550/arXiv.2110.02178.
- [11] K. He, X. Zhang, S. Ren, and J. Sun, ‘Deep Residual Learning for Image Recognition’, presented at the Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016, pp. 770–778. Accessed: Jun. 02, 2026. [Online]. Available: https://openaccess.thecvf.com/content_cvpr_2016/html/He_Deep_Residual_Learning_CVPR_2016_paper.html
- [12] G. Huang, Z. Liu, L. van der Maaten, and K. Q. Weinberger, ‘Densely Connected Convolutional Networks’, presented at the Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017, pp. 4700–4708. Accessed: Nov. 26, 2025. [Online]. Available: https://openaccess.thecvf.com/content_cvpr_2017/html/Huang_Densely_Connected_Convolutional_CVPR_2017_paper.html

- [13] M. Tan and Q. Le, 'EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks', in *Proceedings of the 36th International Conference on Machine Learning*, PMLR, May 2019, pp. 6105–6114. Accessed: Jun. 02, 2026. [Online]. Available: <https://proceedings.mlr.press/v97/tan19a.html>
- [14] W. Gouda, N. U. Sama, G. Al-Waakid, M. Humayun, and N. Z. Jhanjhi, 'Detection of Skin Cancer Based on Skin Lesion Images Using Deep Learning', *Healthcare*, vol. 10, no. 7, p. 1183, Jul. 2022, doi: 10.3390/healthcare10071183.
- [15] I. Iqbal, M. Younus, K. Walayat, M. U. Kakar, and J. Ma, 'Automated multi-class classification of skin lesions through deep convolutional neural network with dermoscopic images', *Computerized Medical Imaging and Graphics*, vol. 88, p. 101843, Mar. 2021, doi: 10.1016/j.compmedimag.2020.101843.
- [16] M. Tahir, A. Naeem, H. Malik, J. Tanveer, R. A. Naqvi, and S.-W. Lee, 'DSCC_Net: Multi-Classification Deep Learning Models for Diagnosing of Skin Cancer Using Dermoscopic Images', *Cancers*, vol. 15, no. 7, p. 2179, Jan. 2023, doi: 10.3390/cancers15072179.
- [17] P. Yao *et al.*, 'Single Model Deep Learning on Imbalanced Small Datasets for Skin Lesion Classification', *IEEE Transactions on Medical Imaging*, vol. 41, no. 5, pp. 1242–1254, May 2022, doi: 10.1109/TMI.2021.3136682.
- [18] S. Ayas, 'Multiclass skin lesion classification in dermoscopic images using swin transformer model', *Neural Comput & Applic*, vol. 35, no. 9, pp. 6713–6722, Mar. 2023, doi: 10.1007/s00521-022-08053-z.
- [19] I. Pacal, B. Ozdemir, J. Zeynalov, H. Gasimov, and N. Pacal, 'A novel CNN-ViT-based deep learning model for early skin cancer diagnosis', *Biomedical Signal Processing and Control*, vol. 104, p. 107627, Jun. 2025, doi: 10.1016/j.bspc.2025.107627.
- [20] N. Nigar, M. Umar, M. K. Shahzad, S. Islam, and D. Abalo, 'A Deep Learning Approach Based on Explainable Artificial Intelligence for Skin Lesion Classification', *IEEE Access*, vol. 10, pp. 113715–113725, 2022, doi: 10.1109/ACCESS.2022.3217217.
- [21] B. Ozdemir and I. Pacal, 'A robust deep learning framework for multiclass skin cancer classification', *Sci Rep*, vol. 15, no. 1, p. 4938, Feb. 2025, doi: 10.1038/s41598-025-89230-7.
- [22] N. Gessert, M. Nielsen, M. Shaikh, R. Werner, and A. Schlaefel, 'Skin lesion classification using ensembles of multi-resolution EfficientNets with meta data', *MethodsX*, vol. 7, p. 100864, Jan. 2020, doi: 10.1016/j.mex.2020.100864.
- [23] M. A. Kassem, K. M. Hosny, and M. M. Fouad, 'Skin lesions classification into eight classes for ISIC 2019 using deep convolutional neural network and transfer learning', *IEEE access*, vol. 8, pp. 114822–114832, 2020.
- [24] Z. Zhang and M. Sabuncu, 'Generalized Cross Entropy Loss for Training Deep Neural Networks with Noisy Labels', in *Advances in Neural Information Processing Systems*, Curran Associates, Inc., 2018. Accessed: Jun. 02, 2026. [Online]. Available: <https://proceedings.neurips.cc/paper/2018/hash/f2925f97bc13ad2852a7a551802feca0-Abstract.html>
- [25] M. T. R *et al.*, 'Transformative Breast Cancer Diagnosis using CNNs with Optimized ReduceLROnPlateau and Early Stopping Enhancements', *Int J Comput Intell Syst*, vol. 17, no. 1, p. 14, Jan. 2024, doi: 10.1007/s44196-023-00397-1.
- [26] L. Prechelt, 'Early Stopping - But When?', in *Neural Networks: Tricks of the Trade*, G. B. Orr and K.-R. Müller, Eds, Berlin, Heidelberg: Springer, 1998, pp. 55–69. doi: 10.1007/3-540-49430-8_3.
- [27] C. Goutte and E. Gaussier, 'A Probabilistic Interpretation of Precision, Recall and F-Score, with Implication for Evaluation', in *Advances in Information Retrieval*, D. E. Losada and J. M. Fernández-Luna, Eds, Berlin, Heidelberg: Springer, 2005, pp. 345–359. doi: 10.1007/978-3-540-31865-1_25.